Word2Vecによる単語のベクトル化

実装のきっかけ

RAGで「文章をベクトル化して検索する」という話に触れました。

文章 → ベクトル → 近い文書を検索

> その数字は、何からどう学習して決まるのでしょうか。

まずは単語を扱うWord2Vecを実装し、
数値の作り方と、学習前後の単語の関係を確かめました。

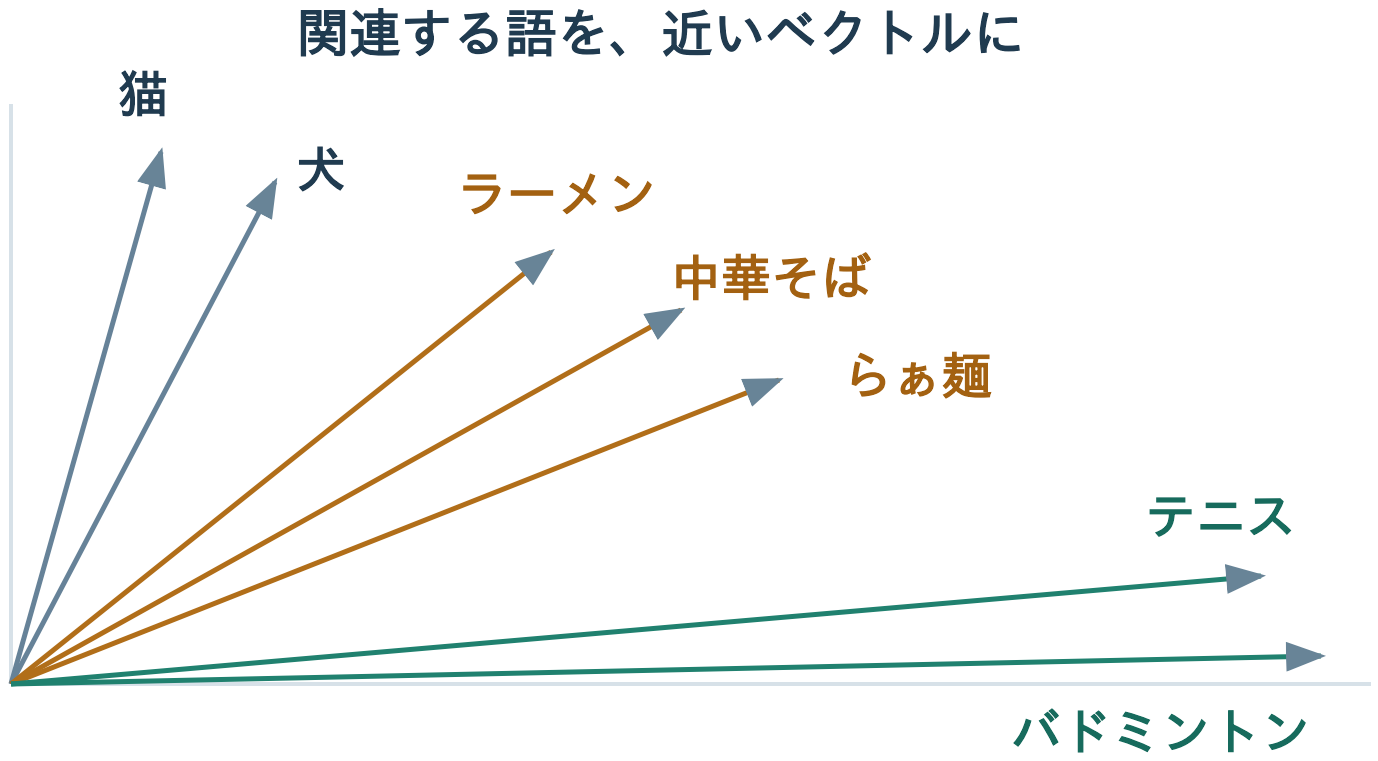
検索に使える単語の関係

「ラーメン」で、中華そばやらぁ麺のお店の情報も見つけたい。

検索：ラーメン

見つけたい情報

- ラーメンのお店の記事
- 中華そばのお店の記事
- らぁ麺のお店の記事

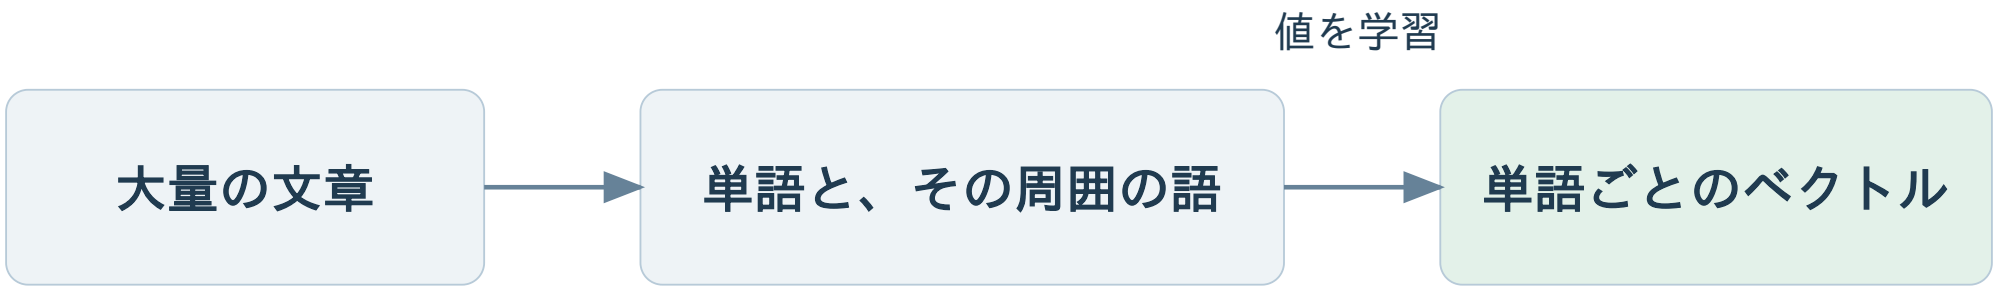


こうした単語の関係を表す数値を、どう決めればよいでしょうか。

文章からの学習

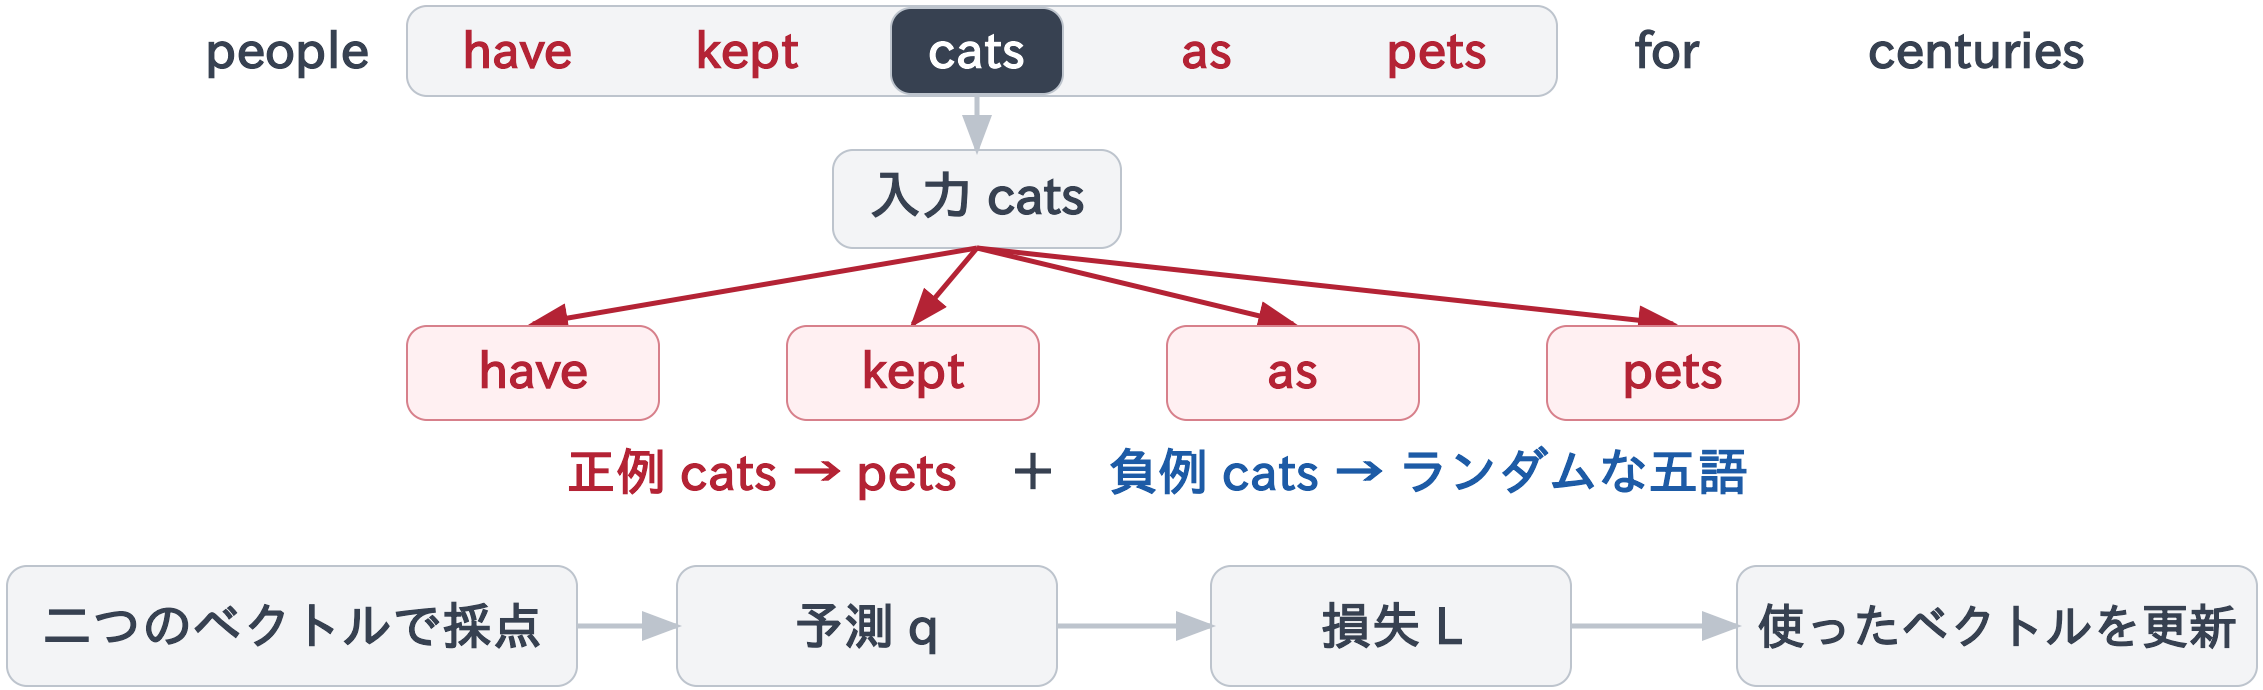
どの単語の近くに、どんな単語が現れるか。

大量の文章にある、単語どうしの使われ方を学習に使います。



使った方法：Skip-gram ＋ Negative Sampling

Skip-gram + Negative Sampling



周辺語とのペアは高く、ランダムな語とのペアは低く予測するよう、ベクトルの値を更新します。

$$v_{\text{cats}}^{(n+1)} = v_{\text{cats}}^{(n)} - \eta \nabla_{v_{\text{cats}}} L$$

n：更新回数　η：学習率　L：正例・負例から計算する損失

正例と負例

ペアを作る → 二つのベクトルで採点 → 予測 q → 損失 L → 更新

中心語 cats | 正例 pets | 負例 tennis / road / train / kitchen / city

people have kept **cats** as pets for centuries

実際の周辺語とのペア：正例

catsの左右2語を、一語ずつ相手にします。

cats → have	cats → kept
cats → as	cats → pets

抽出した語とのペア：負例

cats → tennis、road、train、kitchen、city

語彙から5語をランダムに抽出します。

周辺語とのペアは、高く予測したい

抽出した語とのペアは、低く予測したい

以後は、正例cats → petsと負例5個を一組として追います。

二つのベクトルと予測

ペアを作る → **二つのベクトルで採点** → **予測 q** → 損失 L → 更新

中心語 cats | **正例 pets** | **負例 tennis / road / train / kitchen / city**

入力用と候補用の表

入力用 cats
v = [0.200, −0.100]

相手語wの候補用の行
u_wを取り出します。

sが高い → qは1に近い
sが低い → qは0に近い

相手語	候補用 u_w	点数 s	予測値 q
正例 pets	[0.400, 0.200]	0.060	0.515
負例 tennis	[0.100, 0.300]	−0.010	0.498
負例 road	[−0.200, 0.400]	−0.080	0.480
負例 train	[0.300, −0.100]	0.070	0.517
負例 kitchen	[−0.400, −0.200]	−0.060	0.485
負例 city	[0.200, −0.300]	0.070	0.517

$$s_w = v \cdot u_w, \qquad q_w = \frac{1}{1 + e^{-s_w}}$$

qは0〜1の予測値。正例petsでは上げ、負例tennisなどでは下げたい。

正例・負例の損失

ペアを作る → 二つのベクトルで採点 → 予測 q → **損失 L** → 更新

中心語 cats ｜ **正例 pets** ｜ **負例 tennis / road / train / kitchen / city**

正例：q_+ を上げたい → 1へ

負例：$q_{-,k}$ を下げたい → 0へ

この二つの目標を、損失Lを小さくする一つの計算にまとめます。
正例はq、負例は1−qに−logをかけ、6ペア分を足します。

$$L_+ = -\log q_+, \qquad L_- = -\sum_{k=1}^{5} \log(1 - q_{-,k}), \qquad L = L_+ + L_-$$

正例1個の損失		負例5個の損失		一組の損失
$L_+ = 0.664$	+	$L_- = 3.463$	=	$L = 4.127$

正例：$q_+ = 0.515$ ｜ 負例：q = 0.498 / 0.480 / 0.517 / 0.485 / 0.517

k：負例1〜5の番号。logは自然対数です。

ベクトルの更新

ペアを作る → 二つのベクトルで採点 → 予測 q → 損失 L → 更新

中心語 cats | 正例 pets | 負例 tennis / road / train / kitchen / city

損失が小さくなる向きへ動かす

$$v_{\text{cats}}^{(n+1)} = v_{\text{cats}}^{(n)} - \eta \nabla_{v_{\text{cats}}} L$$

微分で、動かす向きを求めます。
一回に動かす大きさはηで調整します。

入力用catsと、今回使った
候補用6語のベクトルを更新します。

n：更新回数　η：学習率
L：正例1個・負例5個を合わせた損失

ベクトルの値が変わる

行	更新前	更新後
入力 cats	[0.200, −0.100]	[0.218, −0.094]
候補 pets	[0.400, 0.200]	[0.410, 0.195]
候補 tennis	[0.100, 0.300]	[0.090, 0.305]

この組の損失：**4.127 → 4.116**

更新した二表で、次の組を予測

計算例：$\eta = 0.1$。表は更新した行の一部。

似た使われ方と似たベクトル

目的：猫と犬のように、使われ方の似た語を近いベクトルで表したい。

people have kept **cats** / **dogs** as pets for centuries



> 周辺語が共通すると、同じ相手に対して似た予測をするように学習します。

こうした使われ方の共通点が、入力用ベクトルどうしの関係に現れることを期待します。

実験に使った文章と学習条件

ここまでの2次元の計算例から、実際の文章を使った50次元の学習へ。

文章から学習問題を作る

WikiText-2：英語Wikipedia由来
約10万語の文章を使用

使う語彙：**2,000種類**
左右2語から**約24万の正例ペア**

各正例に、**負例を5個**付けます。

二つの表を繰り返し更新する

入力用・候補用とも
2,000語 × 50成分の表

128組ずつまとめて更新
全学習ペアを**200周**

一回に動かす大きさ：学習率 η

> 学習率は、0.75固定・1.0固定・1.0 → 0.01の三条件で比較。

同じ文章・語彙・初期値から開始。入力用は小さな乱数、候補用は0で初期化。

学習の進み具合を同じ問題で測る

一組だけの損失では、問題が変わるたびに難しさも変わります。

そこで学習データから512組を選び、正例も負例も固定して測ります。

固定した512組：各組は正例1個 ＋ 同じ負例5個

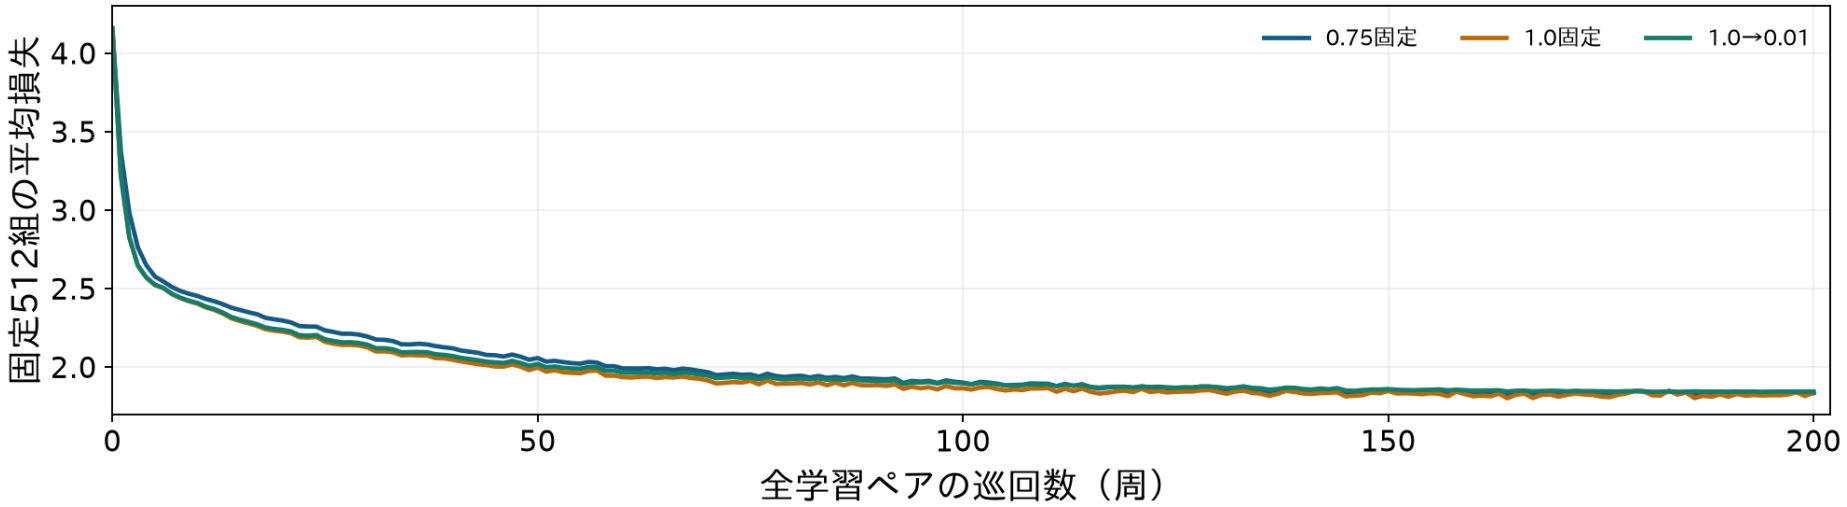
学習前の二表	途中の二表（25周）	学習後の二表（200周）
予測 → 一組の損失 → 平均	予測 → 一組の損失 → 平均	予測 → 一組の損失 → 平均
4.159	2.234	1.835

> 同じ512組への予測がどう変わったかを、平均損失で追います。

図の数値は学習率0.75固定の例。学習データ上での進み具合を見る指標です。

学習中の損失の変化

同じ512組の平均損失。横軸は全学習ペアを何周したか。



学習率	学習前	100周後	200周後
0.75固定	4.159	1.902	1.835
1.0固定	4.159	1.865	1.840
1.0 → 0.01	4.159	1.897	1.845

> 三条件とも損失が低下。以降は200周後の値が最小だった0.75固定を見ます。

学習したベクトルで近い語を探す

ここからは、学習率0.75固定の入力用ベクトル同士を、元の50次元で比べます。

予測が改善したところで、欲しかった単語どうしの関係を確かめます。

入力用の表 → 二語のベクトル → 向きの近さを計算

$$\cos(a, b) = \frac{v_a \cdot v_b}{\|v_a\| \|v_b\|}$$

コサイン類似度：向きがそろうほど1に近くなります。

比較する二語	学習前	200周後
music と song	−0.091	0.517
music と army	0.151	0.275

> musicは、学習後にはarmyよりsongと近い向きになりました。

gameに近い語の変化

入力用・元の50次元のコサイン類似度。自分自身を除く同じ語彙2,000語から上位5語。

一語を選んで、近い語を順に並べます。

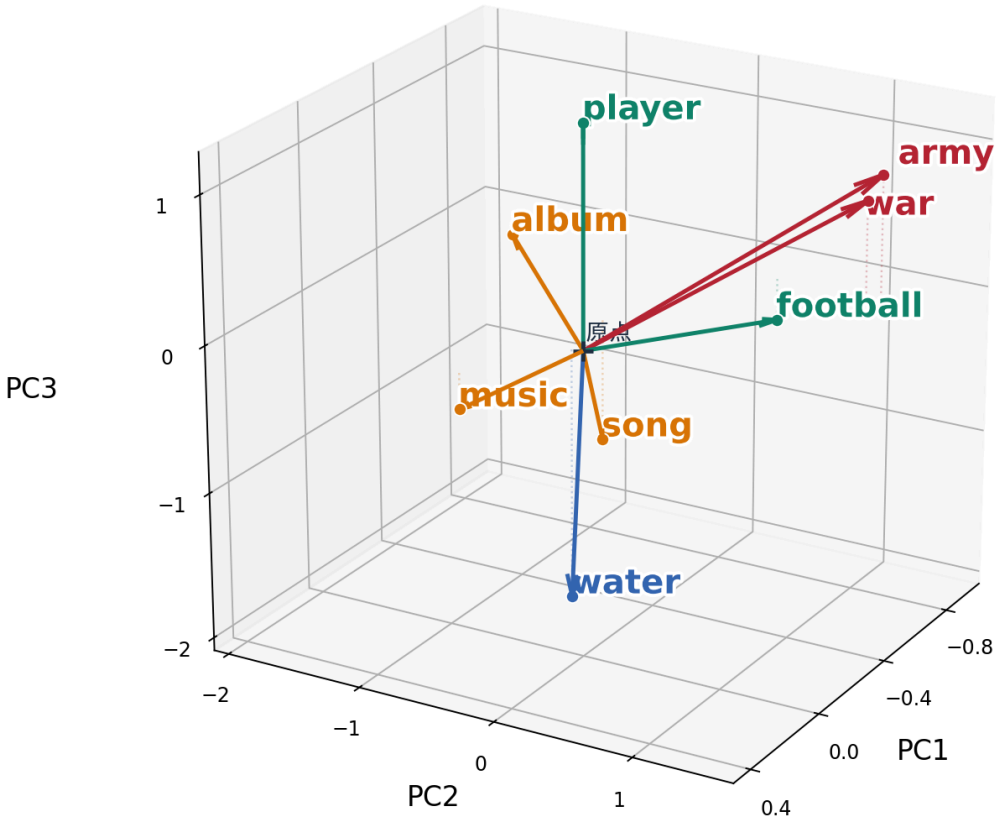
順位	学習前	類似度	200周後	類似度
1	units	0.482	ppg	0.701
2	escape	0.443	losing	0.692
3	battlefield	0.425	nba	0.688
4	church	0.419	season	0.683
5	aircraft	0.407	finals	0.681

> 学習後は、バスケットボールの試合に関連する語が上位に現れました。

ppg：points per game（1試合あたりの得点）。学習率0.75固定の結果。

学習した単語ベクトルの配置

学習率0.75固定・200周後。入力用の全2,000語でPCAを計算し、8語を表示。



armyとwarは、
近い位置に現れています。

前の表で調べた単語の関係を、
配置からも見てみます。

3軸の寄与率：合計11.6%
色は語を読み分けるためのもの。

文章の使われ方から単語の関係を学ぶ

文章の周辺語を手掛かりにベクトルを動かし、
多くの文章で同じ学習を繰り返します。

文章から組を作る

中心語と、その周辺語を
学習するペアにする

→

ベクトルを動かす

正例の予測値を上げ、
負例の予測値を下げる

→

文章全体で繰り返す

共通する周辺語を相手に
学習する更新を重ねる

> この繰り返しから、関連する単語を近い向きに持つベクトルの集まりが得られました。

musicはarmyよりsongに近い

gameから試合関連の語を探せる